Инженерный вычислительный эксперимент: прогнозирование временных рядов

Дисциплина: Промышленное программирование на Python **Модуль:** 4 — Forecasting & Design of Experiments **Автор:** Милехин Виктор Викторович **Дата:** 7 октября 2026

---

1. Постановка задачи

Цель: сравнить три подхода к прогнозированию временного ряда: 1. **Baseline** — «завтра = сегодня». 2. **MLP** — полносвязная нейросеть. 3. **LSTM** — рекуррентная сеть с памятью.

Гипотеза (слайд 26): «LSTM снижает ошибку относительно MLP и baseline на фиксированном TEST».

Метрики: MSE (Mean Squared Error), MAE (Mean Absolute Error).

---

2. Данные

Источник: Yahoo Finance (библиотека `yfinance`). **Инструмент:** AAPL (Apple Inc.), дневные данные. **Период:** 2018-01-02 — 2025-12-31 (2011 наблюдений).

Предобработка (слайд 19, без data leakage): - Разбиение на train/test: **80/20** по времени (не перемешиваем). - Нормализация: `mean` и `std` вычислены **только по train**. - `scaled = (prices - mean_train) / std_train`.

Окна (слайд 7): - Длина окна `WINDOW = 20` (20 предыдущих дней → 1 следующий). - Train: 1592 окна. - Test: 399 окон.

---

3. Архитектуры моделей

MLP (слайд 8)

`Linear(WINDOW → 64) → ReLU → Linear(64 → 1)`

- Вход: вектор 20 значений.
- Выход: одно значение (прогноз цены).

LSTM (слайд 13)

`LSTM(input_size=1, hidden_size=32, batch_first=True) → Linear(32 → 1)`

- Вход: последовательность `[batch, 20, 1]`.
- Выход: одно значение.

Baseline (слайд 5)

`P[t+1] = P[t]`

Прогноз = последнее известное значение.

---

4. Параметры эксперимента

Фиксировано: - `WINDOW = 20` - `EPOCHS = 30` - `BATCH_SIZE = 64` - `OPTIMIZER = Adam` - `SEED = 42`

Фактор (слайд 32): - `LEARNING_RATE in {0.0001, 0.001, 0.01}`

Response (слайд 28): - MSE, MAE, elapsed time.

---

5. Результаты

Итоговая таблица

Модель	lr	MSE	MAE	Время (сек)
Baseline	—	**0.005610**	**0.050677**	—
MLP	0.0001	0.078233	0.241757	1.2
MLP	0.001	0.010349	0.074527	1.2
MLP	**0.01**	**0.007035**	**0.059879**	1.1
LSTM	0.0001	0.843669	0.832503	2.4
LSTM	0.001	0.189894	0.350612	2.3
LSTM	**0.01**	**0.026175**	**0.126045**	2.3

Сравнение с baseline

Модель	MSE vs baseline	Относительное изменение
Best MLP (lr=0.01)	0.007035 vs 0.005610	**+25.4% хуже**
Best LSTM (lr=0.01)	0.026175 vs 0.005610	**+366.6% хуже**

---

6. Интерпретация

6.1. Baseline — сильнейший конкурент

Baseline («завтра = сегодня») даёт **MSE = 0.0056** — это очень низкая ошибка. Причина: **цены акций близки к случайному блужданию**. Сегодняшняя цена — лучший предиктор завтрашней.

Это **ожидаемый результат** для финансовых рядов. Слайд 34 прямо предупреждает: > «Красивый prediction может просто повторять вчерашнюю цену.»

6.2. MLP лучше LSTM на этом датасете

Модель	Лучший MSE
MLP	0.0070
LSTM	0.0262

LSTM в 3.7 раза хуже MLP. Причины: 1. **Мало данных** — 1592 окна недостаточно для LSTM с 32 скрытыми нейронами. 2. **Мало эпох** — 30 эпох недостаточно для рекуррентной сети. 3. **Переобучение** — LSTM склонна запоминать шум на малых данных.

6.3. Learning rate критически важен

lr	MLP MSE	LSTM MSE
0.0001	0.078	0.844
0.001	0.010	0.190
0.01	**0.007**	**0.026**

- **При lr=0.0001** — модели **недоучились** за 30 эпох.
- **При lr=0.01** — **лучший результат** для обеих архитектур.

Вывод: выбор learning rate даёт **11-кратное улучшение** MSE — важнее, чем выбор архитектуры.

---

7. Ограничения эксперимента

1. **Один инструмент** (AAPL) — результаты не обобщаются на все акции.
2. **Один window** (20) — не проверены другие значения.
3. **30 эпох** — мало для LSTM.
4. **Прогноз цен, а не доходностей** — цены нестационарны, baseline слишком силён.
5. **Не учтены транзакционные издержки** — backtest не проводился.

---

8. Инженерный вывод (слайд 36)

Плохо: > «LSTM показала хорошую точность.»

Хорошо (наша формулировка):

> «На фиксированном time split 80/20 ни MLP, ни LSTM **не превзошли baseline** на данных AAPL за 2018–2025. Лучший MLP (lr=0.01) дал MSE=0.0070 против baseline MSE=0.0056 — ухудшение на 25%. LSTM (lr=0.01) дала MSE=0.026 — ухудшение в 4.7 раза. **Это не означает, что модели плохие** — это означает, что **сложность не дала инженерного выигрыша** на задаче, где baseline уже очень сильный. Learning rate критически важен: при lr=0.0001 модели недоучиваются, при lr=0.01 — лучший результат.»

---

9. Что можно улучшить (для будущих экспериментов)

1. **Прогнозировать доходности** `r_t = ln(P_t / P_{t-1})` вместо цен — доходности стационарны, baseline будет слабее.
2. **Больше эпох** — 100–200 для LSTM.
3. **Больше данных** — период 2010–2026.
4. **Другие признаки** — Volume, High-Low, RSI, MACD.
5. **Backtest с транзакционными издержками** — проверка прибыльности.

---

10. Файлы эксперимента

- `forecast_aapl.py` — код эксперимента.
- `figures/aapl_price.png` — цена AAPL.
- `figures/predictions_base.png` — прогнозы на тесте.

- `figures/recursive_base.png` — рекурсивный прогноз на 50 шагов.
- `figures/losses_base.png` — кривые обучения.
- `figures/predictions_lr_0.0001.png` — прогнозы при lr=0.0001.
- `figures/predictions_lr_0.01.png` — прогнозы при lr=0.01.
- `figures/losses_lr_0.0001.png` — кривые при lr=0.0001.
- `figures/losses_lr_0.01.png` — кривые при lr=0.01.

Список источников

1. Презентация «Module 4. Forecasting & Engineering Experiment v2».
2. Слайды 5, 7, 8, 13, 18, 19, 28, 30, 32, 34, 36.
3. Данные: Yahoo Finance via `yfinance`.

---

11. Второй эксперимент: прогноз доходностей

11.1. Постановка

Проблема с первым экспериментом: baseline «завтра = сегодня» оказался очень сильным на **ценах** — потому что цены нестационарны и сильно автокоррелированы.

Решение: прогнозировать **лог-доходности** вместо цен:

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right)$$

Почему это правильно: - Доходности **стационарны** — без тренда. - Слабо автокоррелированы — baseline слабее. - Это **стандарт** в финансовой аналитике.

11.2. Данные

- **Инструмент:** AAPL
- **Период:** 2018-01-02 — 2025-12-31
- **Доходностей:** 2010
- **Средняя доходность:** 0.000949
- **Стандартное отклонение:** 0.019371
- **Train:** 1592, **Test:** 398

11.3. Результаты

Модель	lr	MSE	MAE
Baseline	—	**1.63348138**	**0.83309555**
MLP	0.0001	**0.88090783**	0.61893374
MLP	0.001	0.91378355	0.64491129
MLP	0.01	1.05927944	0.72263747
LSTM	0.0001	0.86366940	0.60237741
LSTM	**0.001**	**0.84137809**	**0.60400450**
LSTM	0.01	0.88416332	0.61715347

11.4. Сравнение с baseline

Модель	MSE vs baseline	Улучшение
Best MLP (lr=0.0001)	0.881 vs 1.633	**−46.1%** [+]
Best LSTM (lr=0.001)	0.841 vs 1.633	**−48.5%** [+]

11.5. Интерпретация

Baseline MSE = 1.633 — это **больше**, чем на ценах (0.0056), потому что доходности почти независимы друг от друга.

Если r_t и r_{t+1} независимы, baseline MSE ≈ 2 × var(r). После нормализации var(r) ≈ 1, значит baseline MSE ≈ 2 — что мы и наблюдаем (1.633).

MLP и LSTM научились предсказывать доходности лучше baseline: - Они улавливают слабую временную структуру (автокорреляцию). - Предсказывают значения ближе к среднему (≈ 0) — это снижает MSE.

Сравнение MLP и LSTM: - **LSTM чуть лучше MLP** на доходностях — она видит временную структуру. - Лучшая LSTM: **MSE = 0.841** (lr=0.001). - Лучшая MLP: **MSE = 0.881** (lr=0.0001).

11.6. Learning rate

lr	MLP MSE	LSTM MSE
0.0001	**0.881** [+]	0.864
0.001	0.914	**0.841** [+]
0.01	1.059	0.884

Для MLP лучше маленький lr, **для LSTM — средний**. Это показывает, что оптимальный learning rate зависит от архитектуры.

11.7. Инженерный вывод

> **На фиксированном time split 80/20 прогноз доходностей AAPL показал:** - **MLP** улучшил baseline MSE на **46.1%** (0.881 vs 1.633). - **LSTM** улучшил baseline MSE на **48.5%** (0.841 vs 1.633).
>
> **Это означает, что выбор целевой переменной критически важен:** - На **ценах** baseline побеждает — потому что цены сильно автокоррелированы. - На **доходностях** нейросети побеждают — потому что доходности слабо автокоррелированы, и модели улавливают временную структуру.
>
> **Для практического применения** важнее прогнозировать доходности, а не цены — это стандарт в финансовой аналитике.

11.8. Ограничения

1. **Транзакционные издержки** не учтены.
2. **Backtest** не проводился — MSE ≠ прибыльность.
3. **Один инструмент** (AAPL) — результаты не обобщаются.
4. **Не проверены другие окна** (5, 10, 50).
5. **Не тестировались другие признаки** (объём, волатильность).

11.9. Файлы второго эксперимента

- `forecast_returns.py` — код.
- `figures_returns/returns_series.png` — график доходностей.
- `figures_returns/returns_predictions_base.png` — прогнозы (lr=0.001).
- `figures_returns/returns_predictions_lr_0.0001.png` — прогнозы (lr=0.0001).
- `figures_returns/returns_predictions_lr_0.01.png` — прогнозы (lr=0.01).
- `figures_returns/returns_losses_*.png` — кривые обучения.

Дата сдачи: октябрь 2026.